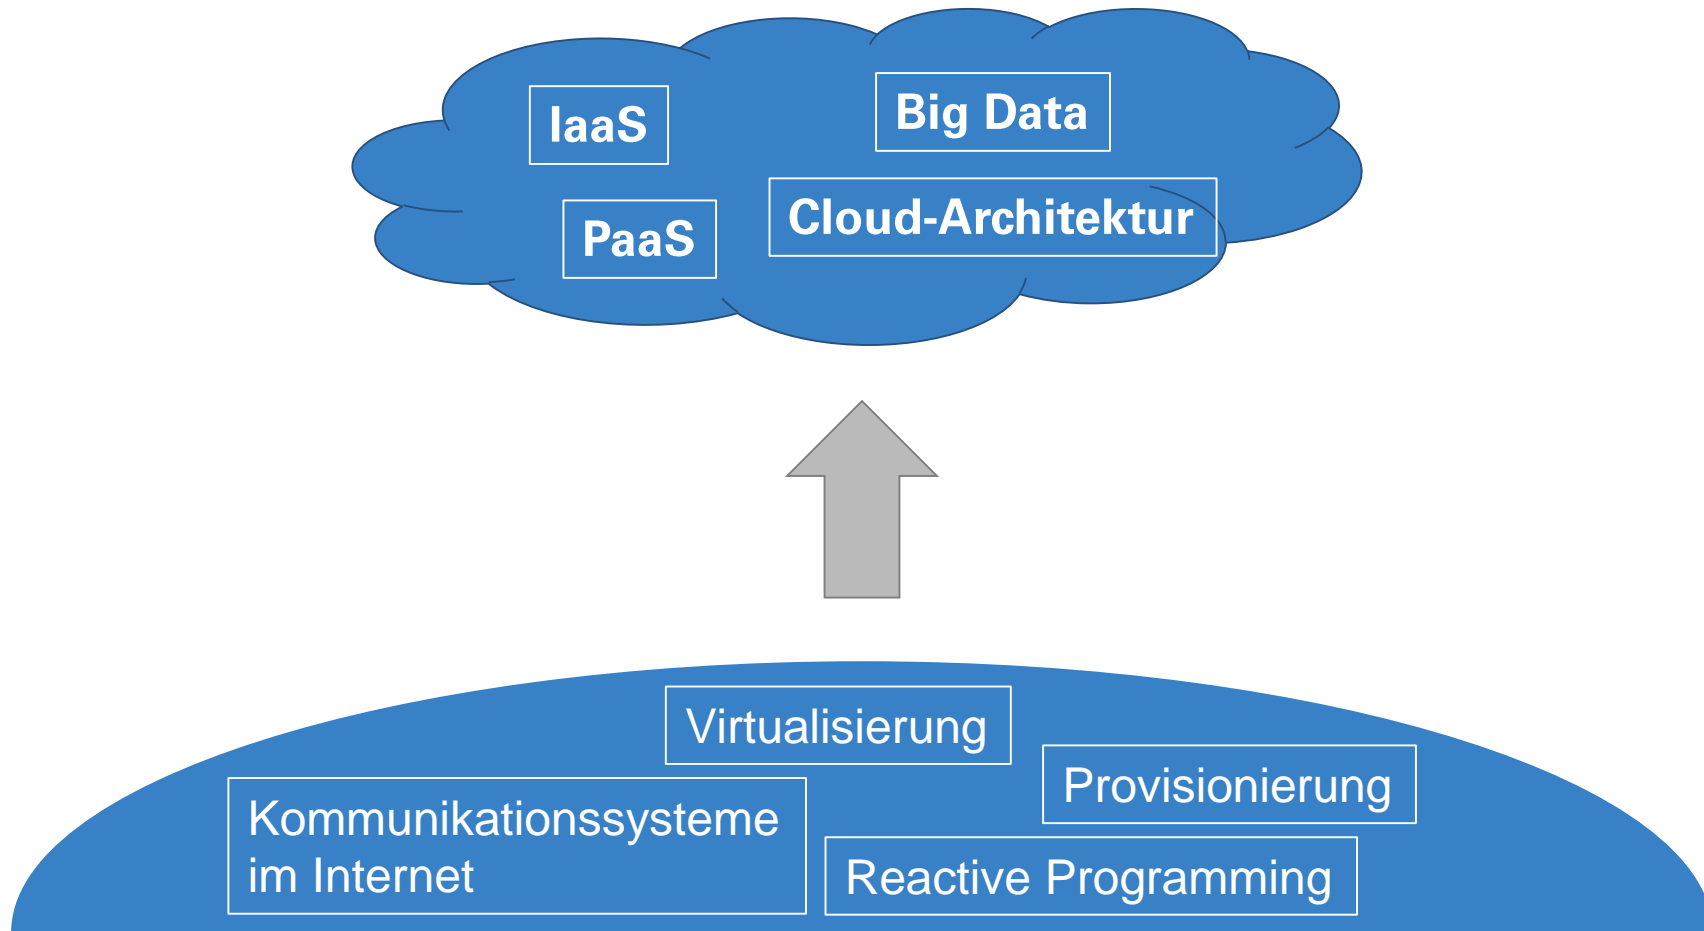


Kapitel 5: Infrastructure-as-a-Service




Vorlesung
CLOUD
COMPUTING


Ab heute sind wir in der Cloud.



Die letzte Vorlesung: Wie kommt Software auf das Blech?




Hardware-Virtualisierung

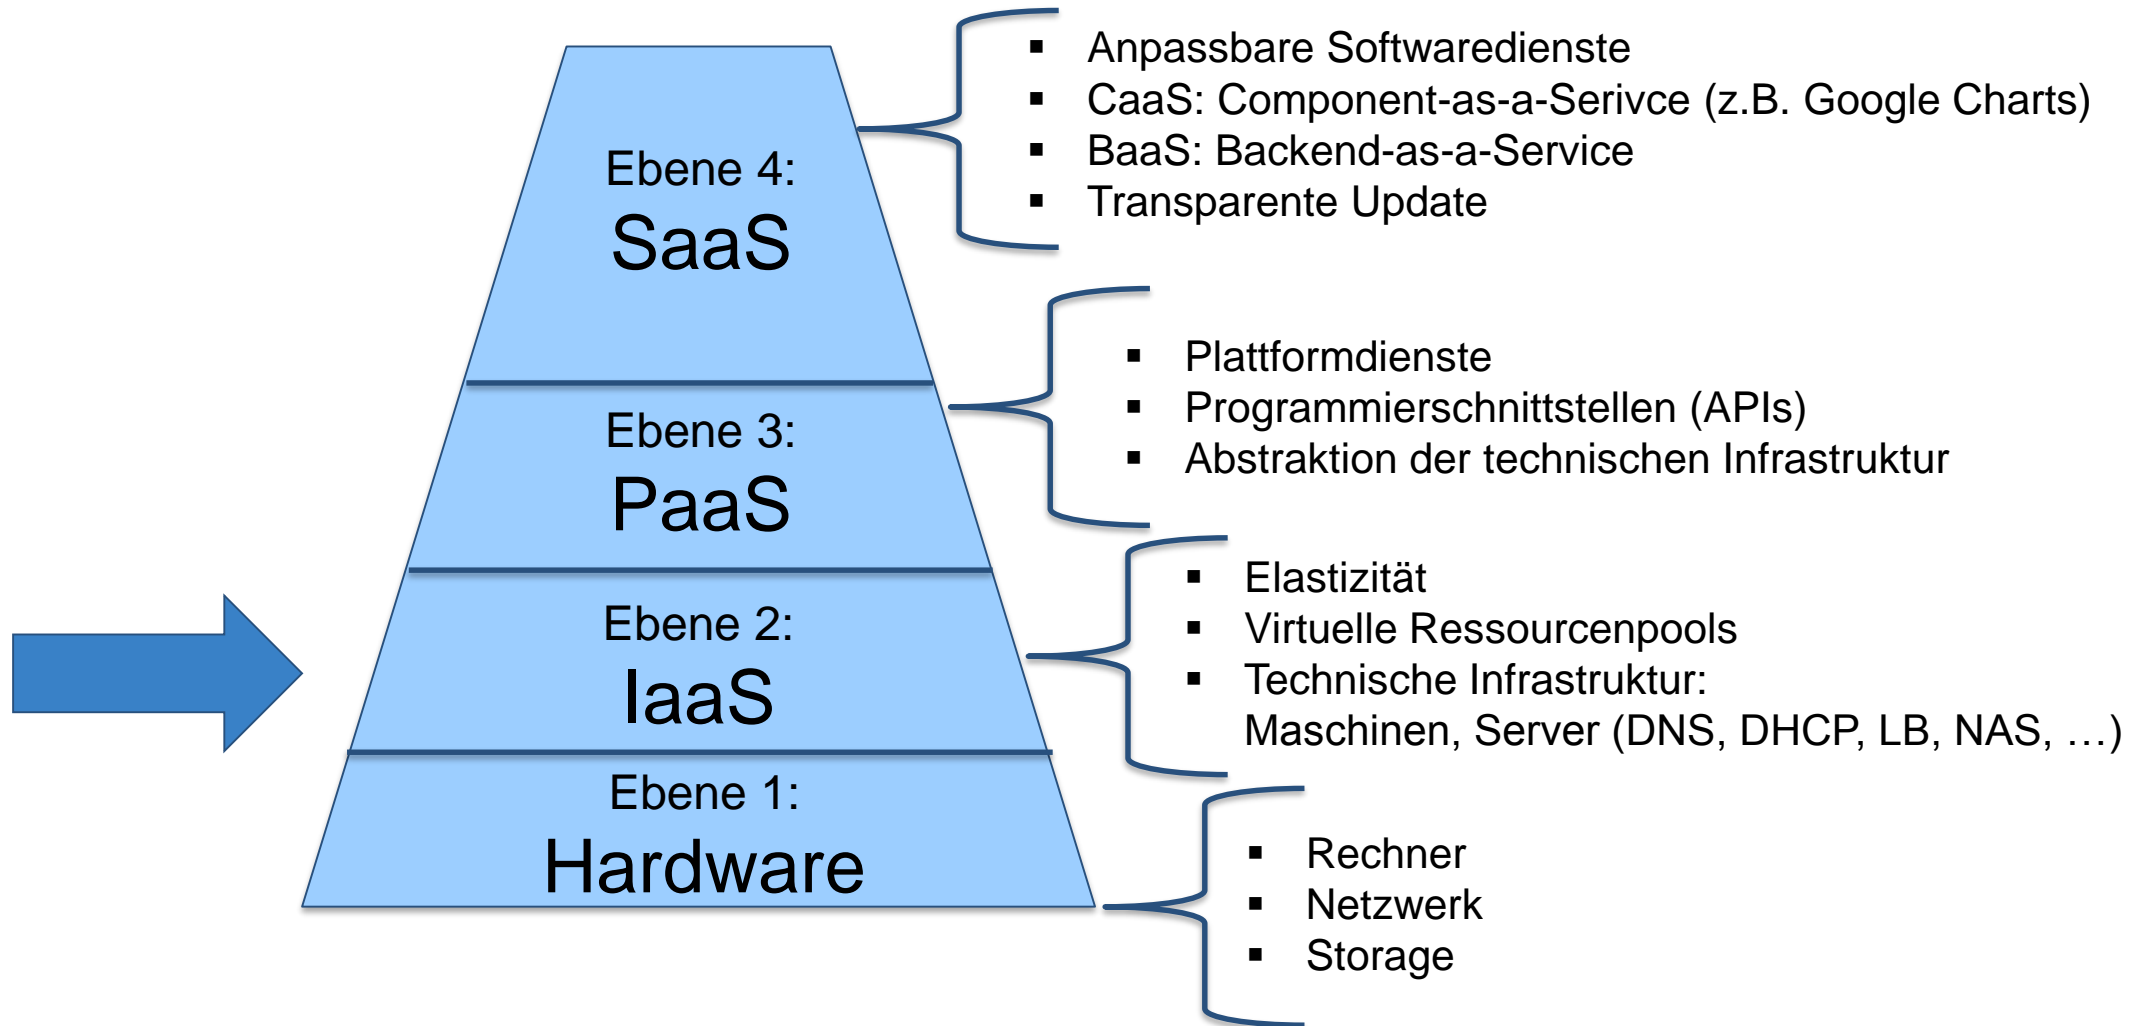


Betriebssystem-Virtualisierung

Heute: Wie kommt Software an das Blech?




Das Schichtenmodell des Cloud Computing: Vom Blech zur Anwendung.



The background is a solid dark blue color with a faint, white, abstract network pattern. This pattern consists of numerous small dots (nodes) connected by thin, white lines (edges), forming a complex, interconnected web that resembles a molecular structure or a data network. The pattern is more dense in some areas and more sparse in others, creating a sense of depth and connectivity.

Einführung: Infrastructure-as-a-Service

Time2System im letzten Jahrhundert: > 1 Jahr.



<http://de.wikipedia.org/wiki/Gro%C3%9Frechner>

Time2System in der Cloud-Ära: In Echtzeit.

Slashdot-Effekt


Der sogenannte **Slashdot-Effekt** oder das **Slashdotting** tritt auf, wenn eine bisher wenig populäre [Website](#) von einem [IT-Online-Magazin](#) wie [Slashdot](#) oder [heise](#) aufgegriffen wird und so binnen Minuten ein erheblicher Benutzeransturm auf die Website beginnt. Dieser führt oft dazu, dass erheblicher [Traffic](#) verursacht wird und der [Server](#) vorübergehend einzelne Anfragen nicht mehr oder nur noch sehr langsam beantworten kann. Die Seite ist dann „geslashdottet“ (engl. *slashdotted*).

Große Websites, die von einer Server-Farm bedient werden, haben meistens keine Probleme mit dem erhöhten Traffic. Es sind vor allem kleinere Einzel-Server, die einem Slashdot-Effekt zum Opfer fallen. Manchmal wird der Slashdot-Effekt scherzhaft mit einem [Distributed-Denial-of-Service](#)-Angriff verglichen.

Um den Ansturm auf die betroffenen Seiten zu reduzieren, werden von unabhängigen Seiten immer wieder [Mirrors](#) angeboten in der Hoffnung, dass die Leser auf die Mirrors anstelle der Originalseite zugreifen. Koordiniert werden solche Projekte von [Coral](#) und [MirrorDot](#).



Klassische Betriebsszenarien werden bei dynamischer Nachfrage teuer. Hohe Opportunitätskosten.



Source: Amazon Web Services

Definition IaaS

Unter *IaaS* versteht man ein Geschäftsmodell, das entgegen dem klassischen Kaufen von Rechnerinfrastruktur vorsieht, diese je nach Bedarf anzumieten und freizugeben.

Eigenschaften einer IaaS-Cloud:

- **Ressourcen-Pools:** Verfügbarkeit von scheinbar unbegrenzten Ressourcen, die Anfragen verteilt verarbeiten.
- **Elastizität:** Dynamische Zuweisung von zusätzlichen Ressourcen bei Bedarf.
- **Pay-as-you-go Modell:** Abgerechnet werden nur verbrauchte Ressourcen.

Ressourcen-Typen in einer IaaS-Cloud:


- **Rechenleistung:** Rechner-Knoten mit CPU, RAM und HD-Speicher.
- **Speicher:** Storage-Kapazitäten als Dateisystem-Mounts oder Datenbanken.
- **Netzwerk:** Netzwerk und Netzwerk-Dienste wie DNS, DHCP, VPN, CDN und Load Balancer.

Infrastruktur-Dienste einer IaaS-Cloud:


- **Monitoring**
- **Ressourcen-Management**

Skalierbarkeit: Effekte

- **Tageszeitliche und saisonale Effekte:** Mittags-Peak, Prime-Time-Peak, Wochenend-Peak, Weihnachten, Valentinstag, Muttertag, ... (vorhersehbare Belastungsspitzen)




- **Kontinuierliches Wachstum**




Source: Amazon Web Services

- **Sondereffekte:** z.B. Slashdot-Effekt (unvorhersehbare Belastungsspitzen)



- **Temporäre Plattformen:** Projekte, Tests, ...



Elastizitätsarten

Nachfrageelastizität: Die allokierten Ressourcen steigen / sinken mit der Nachfrage.



- Pseudo-Elastizität: Schneller Aufbau. Kurze Kündigungsfrist.
- Echtzeit-Elastizität: Allokation und Freigabe von Ressourcen innerhalb von Sekunden. Automatisierter Prozess mit manuellen Triggern oder nach Zeitplan.
- Selbstadaptive Elastizität: Automatische Allokation und Freigabe von Ressourcen in Echtzeit auf Basis von Regeln und Metriken.

Angebotselastizität: Die allokierten Ressourcen steigen / sinken mit dem Angebot.

- Dies ist das typische Verhalten eines Grids: Alle verfügbaren Rechner werden allokiert.
- Es sind auch Varianten verfügbar, bei denen man für freie Ressourcen bieten kann.

Einkommenselastizität: Die allokierten Ressourcen steigen / sinken mit dem Einkommen bzw. dem Budget.


Es gibt vielerlei Anbieter für Public und Private IaaS Clouds.



Der momentane IaaS Markt.



2016 Magic Quadrant for Cloud Infrastructure as a Service, Worldwide, Gartner
<https://aws.amazon.com/de/resources/gartner-2015-mq-learn-more>



Es gibt eine Reihe an gängigen Kriterien bei der Auswahl einer passenden IaaS-Cloud.

- Unterstützte Cloud-Varianten (Private Cloud, Public Cloud, Hybrid Cloud, ...)
- Zuverlässigkeit / Verfügbarkeit
- Sicherheit und Datenschutz
- Vorhersagbare und stabile Performance
- Preismodell: Fixe und flexible Kosten
- Skalierbarkeit: Grenzen, Automatismen und Reaktionszeiten
- Lock-In der Daten und Anwendungen: Offene APIs
- Haftung
- Support

Ein Service Level Agreement (SLA) ist ein Vertrag mit Zuverlässigkeitszusagen für Ressourcen und Dienste.

Verfügbarkeitsklassen:

Availability %	Downtime per Year	Downtime per Month	Downtime per Week
99.9% (three nines)	8.76 hours	43.2 minutes	10.1 minutes
99.95%	4.38 hours	21.56 minutes	5.04 minutes
99.99% (four nines)	52.6 minutes	4.32 minutes	1.01 minutes
99.999% (five nines)	5.26 minutes	25.9 seconds	6.05 seconds
99.9999% (six nines)	31.5 seconds	2.59 seconds	.0605 seconds

Beispiel: Amazon S3 (Storage)

Service Commitment

AWS will use commercially reasonable efforts to make Amazon S3 available with a Monthly Uptime Percentage (defined below) of at least 99.9% during any monthly billing cycle (the "Service Commitment"). In the event Amazon S3 does not meet the Service Commitment, you will be eligible to receive a Service Credit as described below.

Monthly Uptime Percentage	Service Credit Percentage
Equal to or greater than 99% but less than 99.9%	10%
less than 99%	25%


Aspekte der Sicherheit in einer IaaS-Cloud.

- Vertraulichkeit der Daten und Datenkommunikation: Datenverschlüsselung, VPNs
- Nachvollziehbarkeit der Daten: Einhaltung nationaler Gesetze (z.B. EU-Datenschutzbestimmung, US Patriot Act) durch geographische Datenhaltung
- Firewalls und starke Authentifizierungsverfahren
- Backup der VMs, Storages und Datenbanken
- Zertifizierungen: ISO 27001, TÜV IT
- Siehe auch Sopot Memorandum: <http://datenschutz-berlin.de/content/nachrichten/datenschutznachrichten/%2027-april-2012>



Architektur einer IaaS-Cloud

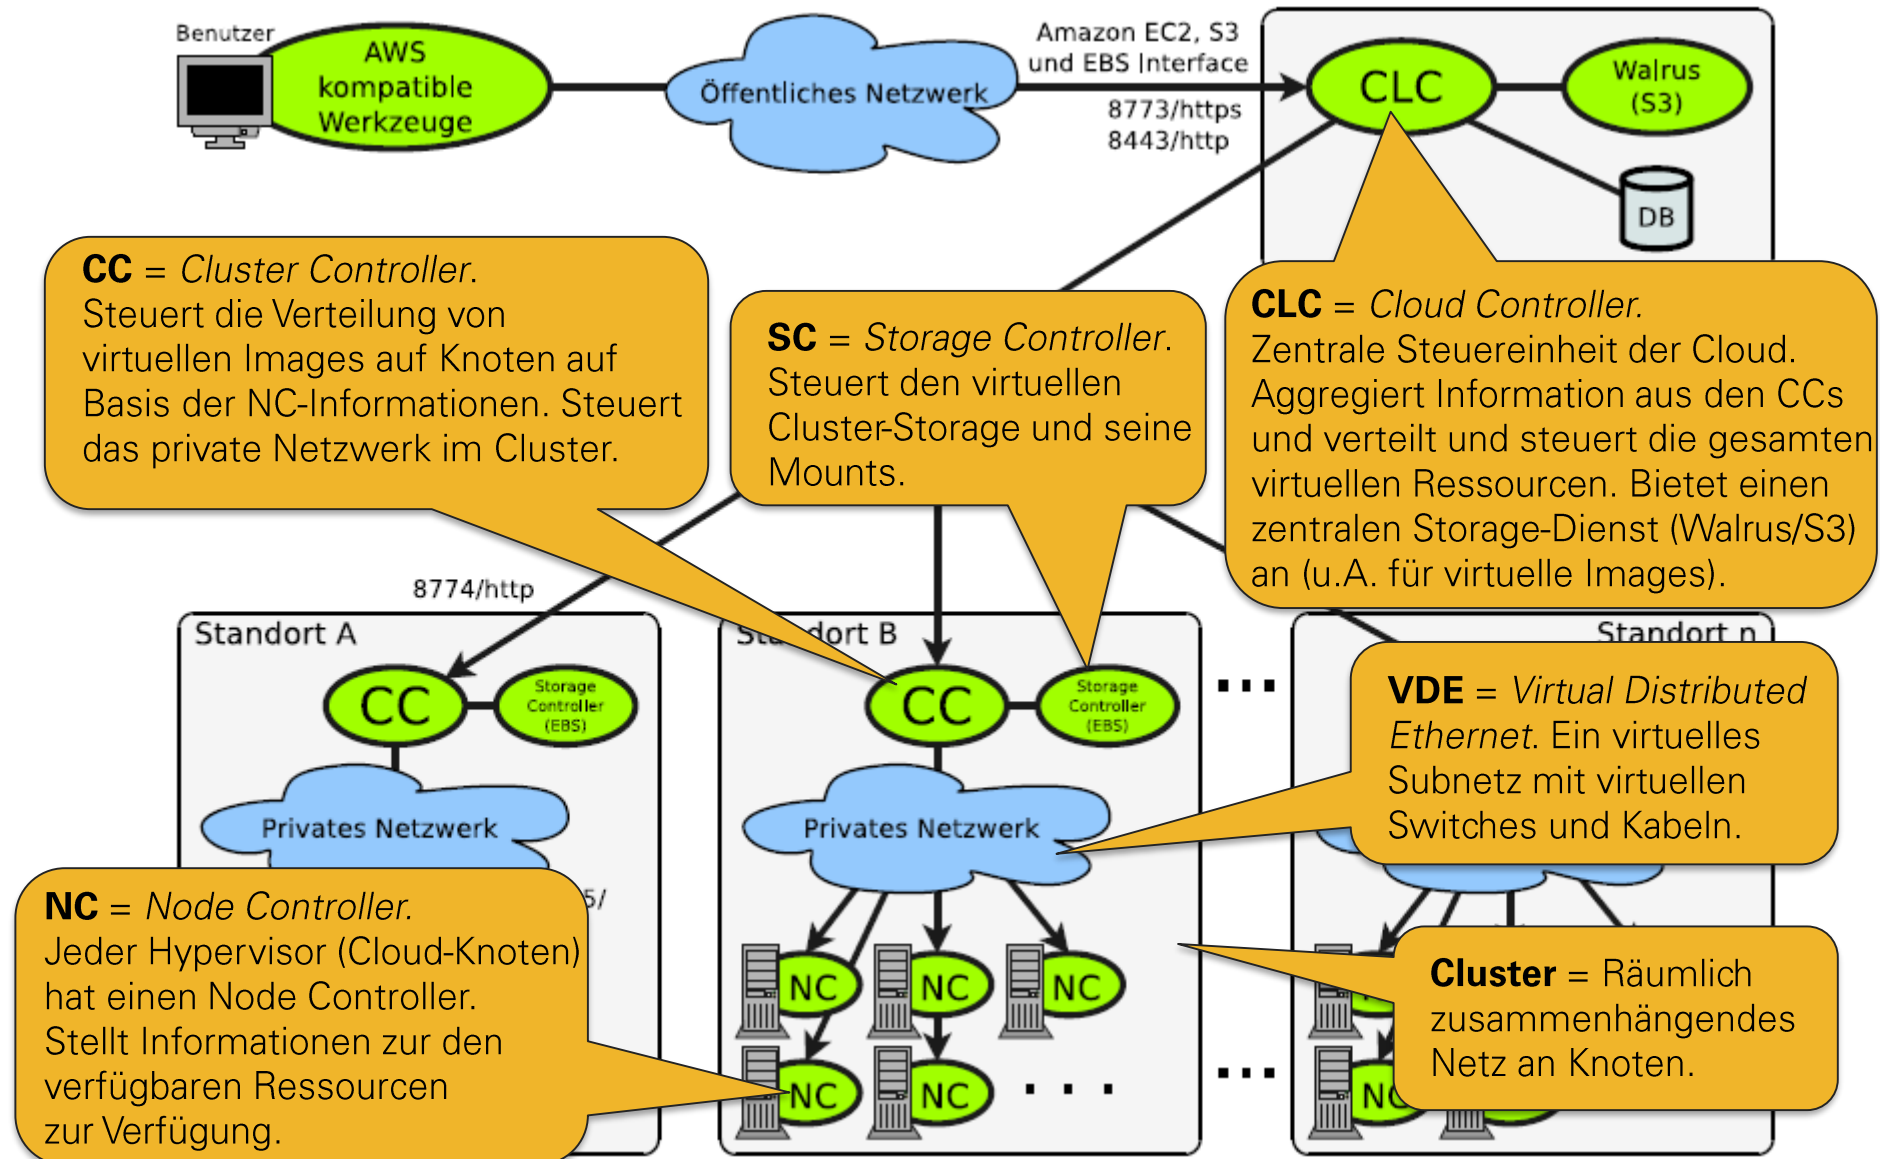
Eine IaaS-Referenzarchitektur.



1. Hardware und Betriebssystem
2. Virtuelles Netzwerk und Netzwerkdienste
3. Virtualisierung
4. Datenspeicher und Image-Verwaltung
5. Managementschnittstelle für Administratoren und Benutzer
6. Cloud Controller für das mandantenspezifische Management der Cloud-Ressourcen

Peter Sempelinski and Douglas Thain,
"A Comparison and Critique of Eucalyptus, OpenNebula and Nimbus",
IEEE International Conference on Cloud Computing Technology and Science, 2010.

Der interne Aufbau einer IaaS-Cloud am Beispiel Eucalyptus.






IaaS mit OpenStack


OpenStack: Der de-facto Standard für Open-Source Private IaaS Clouds.

- Open Source Projekt wurde maßgeblich initiiert von RackSpace und der NASA.
- Das erste vollständige Release erfolgte im Oktober 2010.
- Lizenziert unter der Apache Lizenz.
- Eine Vielzahl der klassischen IT-Player (SAP, IBM, vmWare, HP, Oracle, Cisco) sind Teil der OpenStack-Community.
- Sehr aktives Open-Source-Projekt mit > 400 aktiven Committern.
- Ausgelegt eher als Framework denn als fertiges System für IaaS-Clouds.




The Battle is Over (open src)

OpenStack Launch



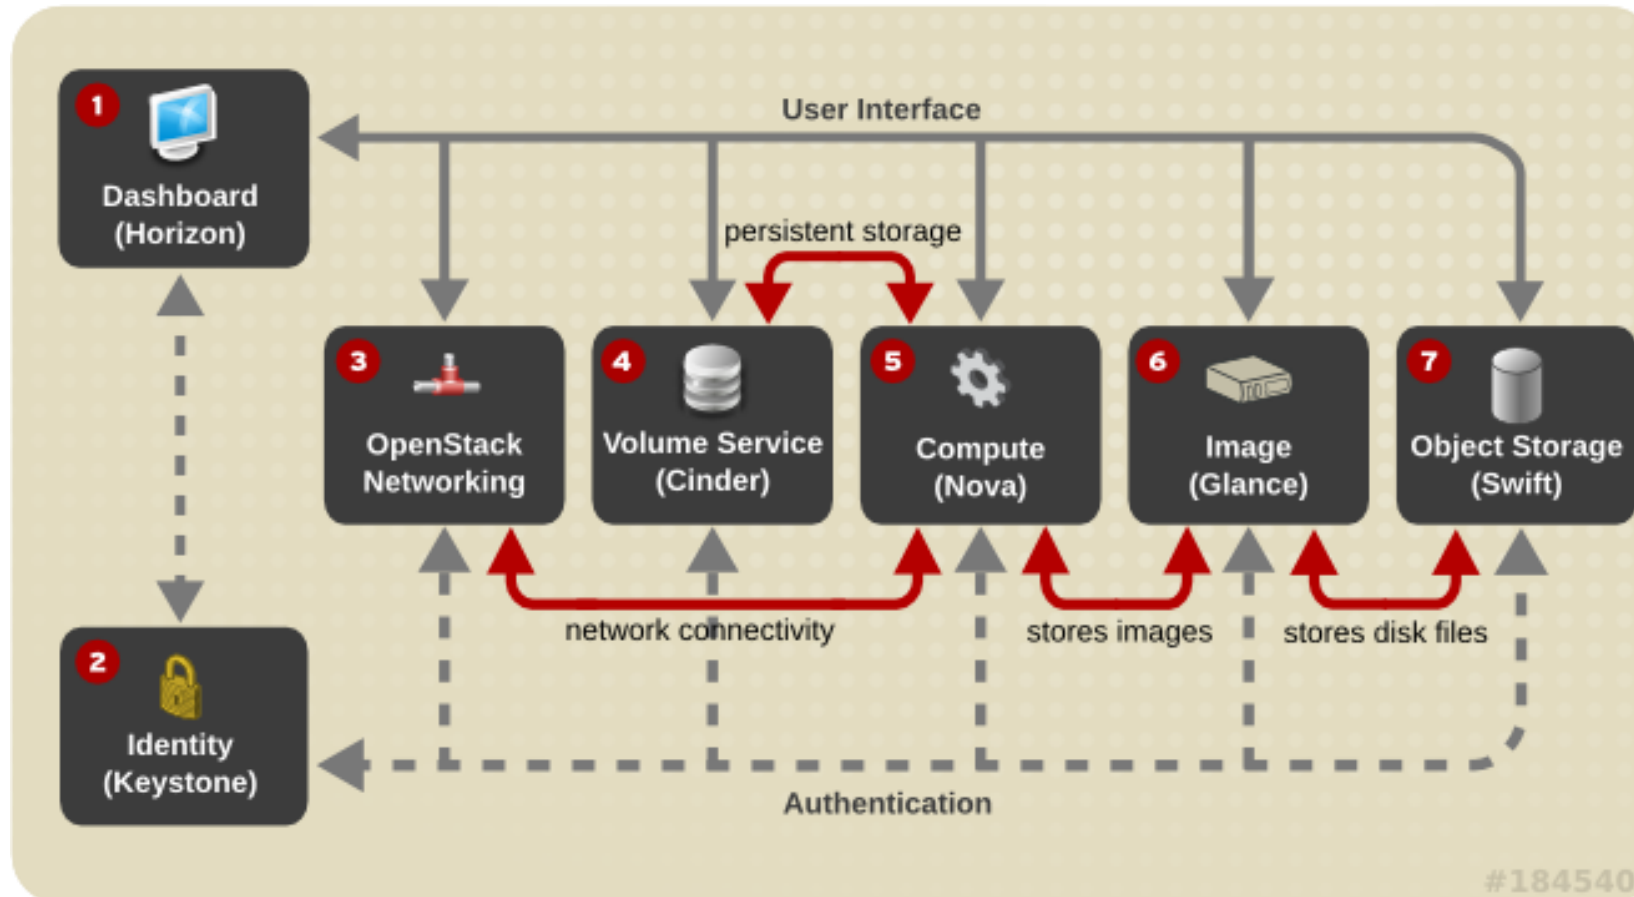
Quellen: <http://de.slideshare.net/randybias/state-of-the-stack-v2>

Die OpenStack Komponenten.



Quelle: <http://de.slideshare.net/sgordon2/deep-dive-openstack-summit-red-hat-summit-2014>

Das Zusammenspiel der Kern-Komponenten in OpenStack.




Quelle: https://access.redhat.com/documentation/en-US/Red_Hat_Enterprise_Linux_OpenStack_Platform/2/html/Getting_Started_Guide/ch01.html

IaaS mit Amazon EC2

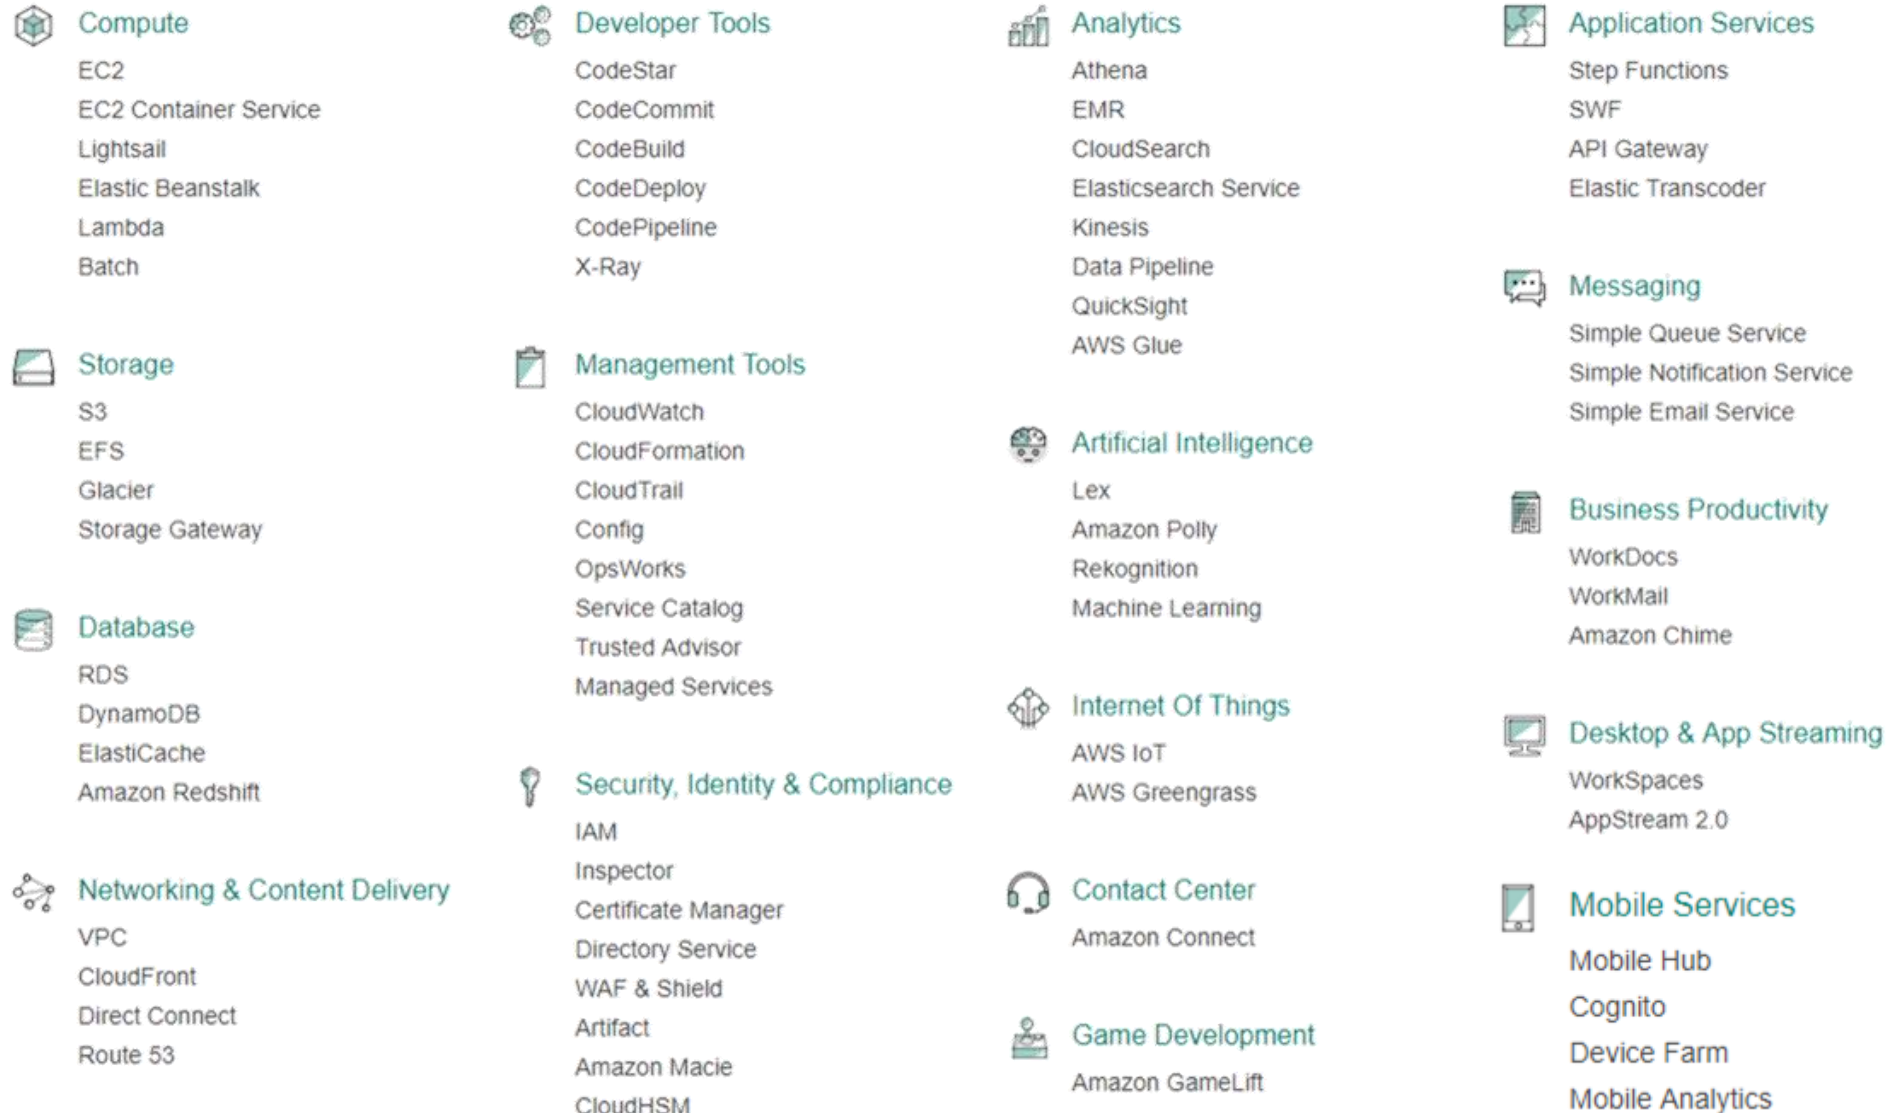
Die Amazon EC2 IaaS Cloud.

- Amazon bietet im Rahmen der AWS (Amazon Web Service) auch eine IaaS-Cloud an.
- Historie:
 - Start innerhalb von Amazon im Jahr 2001
 - Öffentliche Beta ab 25. August 2006
 - Ab Mitte 2007 mehr Bandbreite durch Dritte in der Cloud konsumiert, als durch die Amazon Webseiten
 - Produktionsreife ab 23. Oktober 2008
 - 2005 bis 2012 ca. 12 Mrd. \$ Investment in die Infrastruktur
 - 2015: 1,5 bis 2 Mio. Server in 10 globalen Rechenzentren.
- On-Demand-, Reserved- und Spot-Instanzen in verschiedenen Größen:
(<http://aws.amazon.com/de/ec2/instance-types>) sowie diverse Storage- und Netzwerkdienste.




<http://aws.typepad.com/aws/2008/05/lots-of-bits.html>

Neben der Amazon EC2 IaaS Cloud bietet Amazon noch viele weitere IaaS-Komponenten, PaaS- und SaaS-Dienste.



Architektur der Amazon EC2.

- AWS Management
- Console
- Webservice-API
- EBS (Elastic Block Store)
- S3 (Simple Storage Service)



- DNS / DHCP
- Elastic IPs
- VPC (Virtual Private Cloud)
- Elastic Load Balancer
- CloudFront CDN

- EC2-Knoten mit Xen- und HVM-Virtualisierung
- Monitoring über CloudWatch
- AutoScaling auf Basis von CloudWatch-Metriken

Die globale Verteilung der Amazon EC2.



Region und Anzahl der Availability Zones

USA Ost

Nord-Virginia (6),
Ohio (3)

USA West

Nordkalifornien (3),
Oregon (3)

Asien-Pazifik

Mumbai (2), Seoul
(2), Singapur (2),
Sydney (3), Tokio (3)

Kanada

Zentral (2)

China

Peking (2)

Europa

Frankfurt (3), Irland
(3), London (2)

Südamerika

São Paulo (3)

**AWS GovCloud (US-
West) (2)**



Neue Region (in Kürze verfügbar)

Bahrain

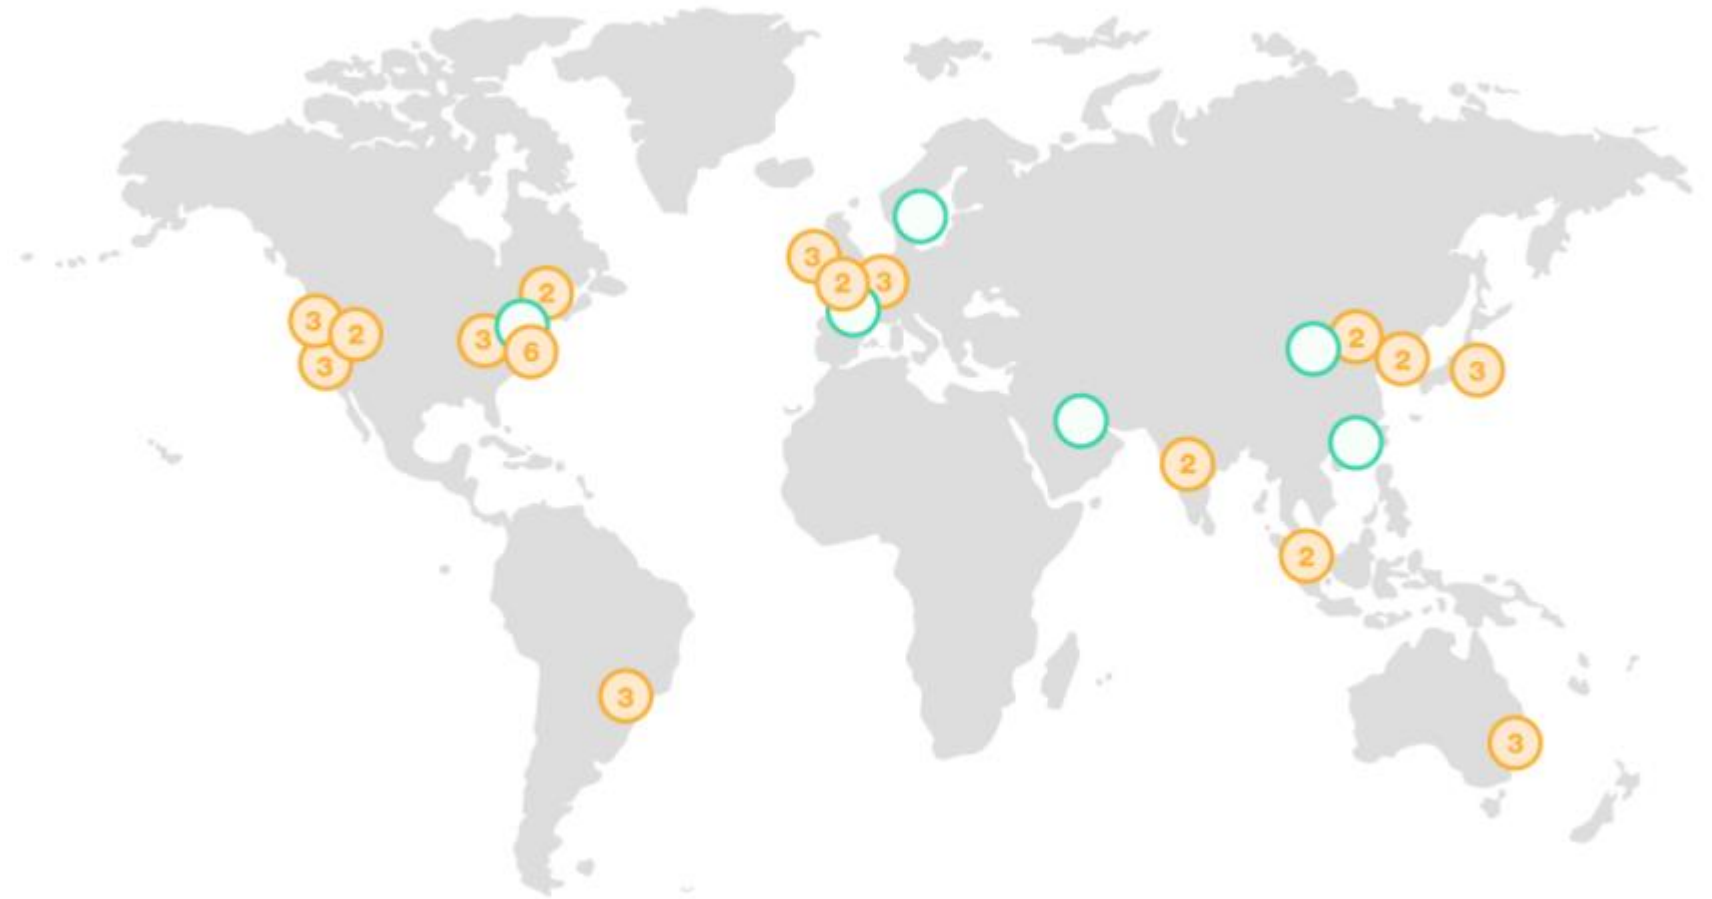
China

Frankreich

Hongkong

Schweden

**AWS GovCloud (US-
East)**



Sicherheitsaspekte der Amazon EC2.



- Zertifiziert nach ISO 27001 (Empfehlung BSI). Im deutschen und irischen Datencenter den EU-Datenschutzrichtlinien unterworfen. Amazon ist ebenso global dem US Patriot Act unterworfen.
- Daten und Instanzen können global auf alle Rechenzentren verteilt werden. Jedes dieser Rechenzentren besteht aus mehreren Verfügbarkeitszonen, die ein in sich geschlossenes Rechen-Cluster darstellen.
- Jede EC2-Instanz muss einer Security Group zugeordnet sein. Eine Security Group ist die Konfiguration der Inbound-Firewall für Instanzen.
- Der Zugriff auf die EC2-Administrationsfunktionen kann über das zentrale IAM-System gesteuert werden. Es können Benutzer angelegt, autorisiert und authentifiziert werden. Für den Zugriff per API können Zugriffsschlüssel und Zertifikate vergeben und widerrufen werden. Eine Multi-Faktor-Authentifizierung wird unterstützt.
- Zugriff auf Linux-Instanzen per SSH. Authentifizierung an der Instanz über SSH-Zertifikat (Keypair) und Benutzername („root“/„ec2-user“/„ubuntu“).
- Zugriff auf Windows-Instanzen per Remote Desktop. Das Admin-Passwort für die Maschine kann per Weboberfläche / API abgefragt werden.

Über die AWS Management Console können alle Dienste der Amazon-Cloud gesteuert werden.

The screenshot displays the AWS Management Console interface for the EC2 Dashboard. The top navigation bar shows the user 'Josef Adersberger' and the region 'Frankfurt'. The left-hand navigation menu lists various services, including EC2 Dashboard, INSTANCES, IMAGES, ELASTIC BLOCK STORE, NETWORK & SECURITY, and AUTO SCALING. The main content area is divided into several sections:

- Resources:** A section titled 'Resources' showing the following counts for Amazon EC2 resources in the EU (Frankfurt) region:
 - 0 Running Instances
 - 0 Elastic IPs
 - 0 Volumes
 - 0 Snapshots
 - 0 Key Pairs
 - 0 Load Balancers
 - 0 Placement Groups
 - 1 Security Group
- Create Instance:** A section titled 'Create Instance' with a 'Launch Instance' button. It includes a note: 'Note: Your instances will launch in the EU (Frankfurt) region'.
- Service Health:** A section titled 'Service Health' showing the status of the EU (Frankfurt) service. It indicates that the service is operating normally across all availability zones (eu-central-1a and eu-central-1b).
- Scheduled Events:** A section titled 'Scheduled Events' showing that there are no events scheduled for the EU (Frankfurt) region.
- Account Attributes:** A section titled 'Account Attributes' showing supported platforms (VPC) and default VPC (vpc-2ef31c47).